

Кредитоспособност (Loan Prediction Project)

1. Вовед

Процесот на одобрување кредити претставува значаен предизвик за финансиските институции поради ризикот од неплаќање на заемите. Точната проценка на кредитната способност е значајна за намалување на финансиските загуби и за донесување објективни одлуки. Со зголемувањето на достапните податоци и комплексноста на факторите што влијаат врз кредитниот ризик, техниките од машинското учење сè повеќе се применуваат како поефикасно решение во однос на традиционалните методи.

Целта на овој проект е да се изгради модел за предвидување на отплата на кредити (loan prediction) врз основа на демографски, финансиски и кредитни податоци за лица што земаат кредит. Проектот се фокусира на бинарна класификација, при што целната променлива `loan_paid_back` означува дали заемот е целосно отплатен или не.

Во рамки на проектот се имплементирани повеќе модели на машинско учење, како што се логистичка регресија, Random Forest, XGBoost, LightGBM и невронска мрежа. Секој модел е развиен и анализиран поединечно, а додатно е креиран и комбиниран модел со цел да се споредат перформансите и да се испита можноста за подобрување на точноста. Проектот е реализиран како дел од факултетски предмет и има за цел практична примена на техники од машинското учење во финансиски контекст.

2. Преглед на податочно множество и дефинирање на проблемот

2.1 Поставување на проблемот

Бидејќи целта на проектот е да се предвиди дали кредитот ќе биде отплатен или не, ова се дефинира како проблем на бинарна класификација.

- Влез:** Демографски информации, финансиски информации, информации за кредитот, кредитна историја на заемопримачот.
- Излез:** Статус на отплата на кредитот(1/0).

Доколку се одобри кредитот кој подоцна ќе престане да се отплатува, тоа доведува до финансиска загуба. Од друга страна, одбивањето на кредит кој би бил отплатен од корисникот може да доведе до потенцијално намален профит. Типот на предвидување ги разгледува двете страни на проблемот, а прецизноста сама по себе не е секогаш доволна за целосно оценување на ризиците.

2.2 Опис на податочно множество

Податочното множество што се користи за проектот е Loan Prediction Dataset 2025 преземено од Kaggle, кое содржи синтетички податоци кои се продукт од алгоритми тренирани на реални податочни множества. Вкупно, содржи 20.000 апликации за кредит, каде што секоја претставува еден корисник.

Атрибути во податочно множество

1. Демографски податоци за заемопримачот

- **age (int64)** – Возраст на заемопримачот (во години).
- **gender (category)** – Пол на заемопримачот (Машки/Женски/Друго).
- **marital_status (category)** – Брачен статус (Самец, Во брак, Разведе/ан, Вдовец/вица).
- **education_level (category)** – Ниво на образование (Средно образование, Додипломски студии, Магистерски студии, Докторски студии, Друго).

2. Финансиски информации

- **annual_income (float64)** – Годишен приход на заемопримачот.(6000.0 до 400000.0)
- **monthly_income (float64)** – Месечен приход на заемопримачот.(500.0 до 33333.33)
- **employment_status (category)** – Тековен работен статус (Вработен, Самовработен, Невработен, Студент, Пензиониран).
- **debt_to_income_ratio (float64)** – Однос помеѓу долг и годишен приход на заемопримачот. Пониска вредност = подобро.(0.01 до 0.667)
- **credit_score (int64)** – Кредитен рейтинг од кредитно биро (на пр. FICO). Повисока вредност = помал ризик различни бироа користат различни скали но тоа еично во интервал од 300 до 850 каде 850 е совршен а 300 би било многу лош(373 до 850 во обработуваното податочно множество)

3. Информации за заемот

- **loan_amount (float64)** – Износ на земениот заем.(500.0 до 49039.69)
- **loan_purpose (category)** – Намената на заемот (Автомобил, Консолидација на долг, Бизнис, Образование, Дом, Медицински трошоци, Патување/Одмор, Друго.)
- **interest_rate (float64)** – Годишна каматна стапка на заемот (од 3.14% до 22.51%).
- **loan_term (int64)** – Рок на отплата на заемот (во месеци, од 36 до 60).
- **installment (float64)** – Месечна рата.(9.43 до 1685.4)
- **grade_subgrade (category)** – Ризична категорија доделена на заемот (A1 до F5.).

4. Кредитна историја на заемопримачот

- **num_of_open_accounts (int64)** – Вкупен број на активни кредитни сметки.(0 до 15)
- **total_credit_limit (float64)** – Вкупен расположлив кредитен лимит на заемопримачот.(6157.8 до 454394.19)
- **current_balance (float64)** – Тековен неплатен износ (заеми + кредитни картички) (496.35 до 352177.9)
- **delinquency_history (int64)** – Број на задочнети плаќања во историјата на заемопримачот.(0 до 11)
- **public_records (int64)** – Негативни јавни записи (на пр. банкроти, правни постапки) (0 до 2)
- **num_of_delinquencies (int64)** – Вкупен број на доцнења (пропуштени плаќања) (0 до 11)

5. Целна променлива

- **loan_paid_back (int64)** – Целна променлива:
 - **1** → Заемопримачот го отплатил заемот во целост.
 - **0** → Заемопримачот направил неисполнување на обврските (не го отплатил целосно).

2.3 Распределба на целната променлива

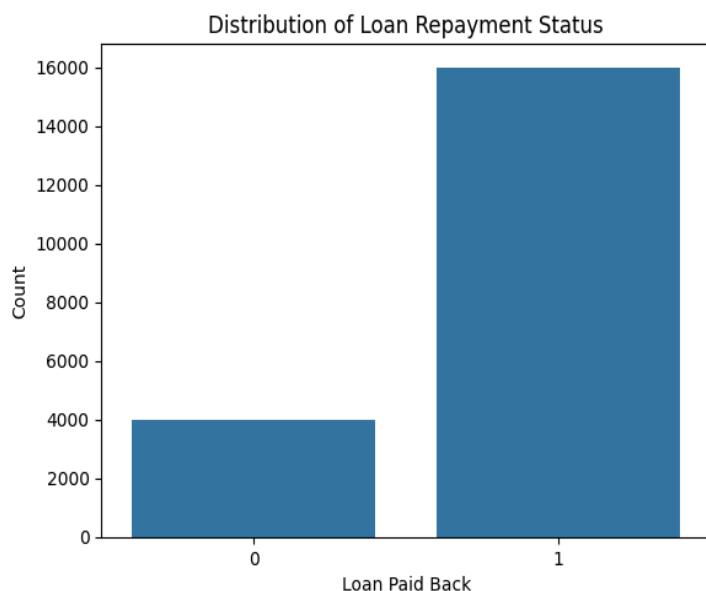
Целната променлива е `loan_paid_back`, која покажува дали кредитот е отплатен или не.

- 1 - кредитот е отплатен (16.000 примероци)
- 0 - кредитот не е отплатен (4000 примероци)

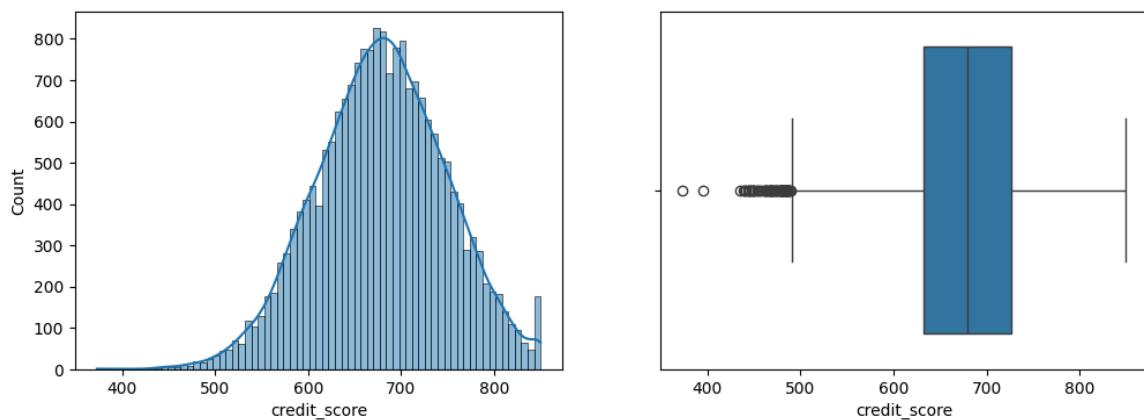
Поради оваа небалансираност, моделот може да постигне висока прецизност, но и да создаде голем број на предвидувања што може да предизвикаат ненамерни, но скапи последици. Како резултат, проектот се фокусира на анализирање на лажните позитиви и лажните негативи. Овој пристап е особено значаен за системите за одобрување на кредити, каде што минимизирањето на ризичните одобрувања има поголемо значење отколку постигнување на висока прецизност.

2.4 Експлоративна анализа на податоците (Exploratory Data Analysis – EDA)

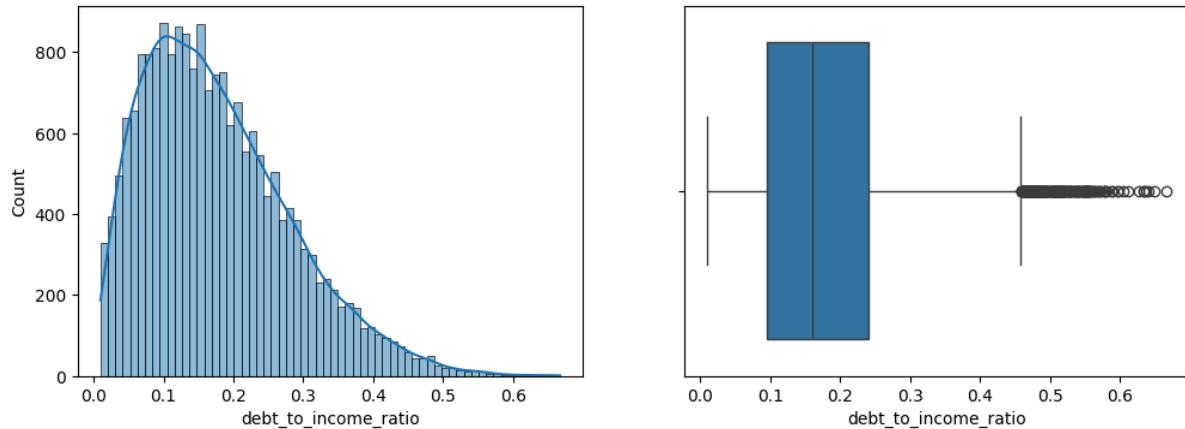
Со цел подобро разбирање на податочното множество и односите помеѓу карактеристиките и целната променлива, беше спроведена експлоративна анализа на податоците (EDA). Оваа анализа има за цел да ги идентификува основните распределби, потенцијалните аномалии, како и клучните фактори кои влијаат врз веројатноста за отплата на кредитот.



Распределбата на целната променлива покажува јасна небалансираност, при што околу 80% од заемите се успешно отплатени, додека околу 20% резултирале со неисполнување на обврските. Ова укажува дека прецизноста сама по себе не е доволна метрика и дека е потребно внимателно разгледување на лажните позитиви и негативи, Особено лажните позитиви кои би значеле одобрување кредит на лице кое нема да го врати што директно се преведува во загуби за банката.

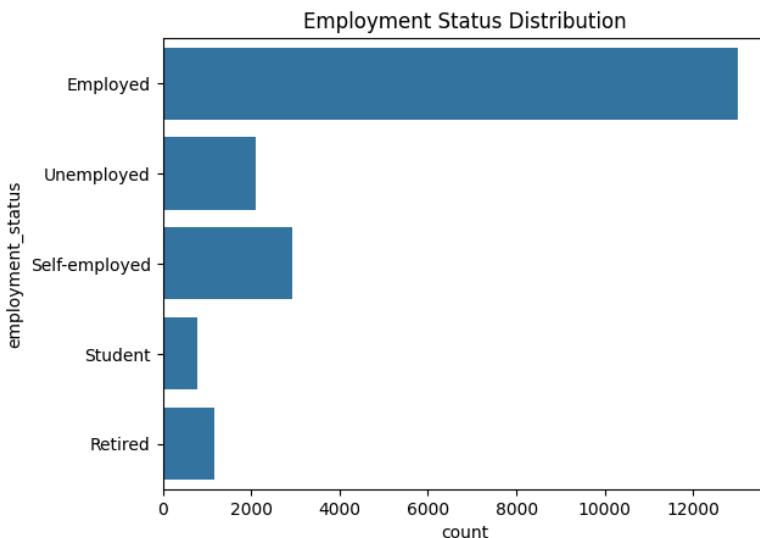


Анализата на кредитниот рејтинг покажува приближно нормална распределба, со јасна концентрација на заемопримачи во интервалот од околу 650 до 700 поени. Најголемиот дел од апликациите доаѓаат од лица со среден до повисок кредитен профил. Box-plot визуелизацијата дополнително покажува дека иако најголемиот дел од вредностите се групирани околу медијаната, постои мал број на заемопримачи со значително пониски кредитни рејтинзи, кои се појавуваат како екстремни вредности (outliers). Овие пониски кредитни рејтинзи се особено значајни од аспект на кредитен ризик, бидејќи претставуваат корисници со послаба историја на отплата и повисока веројатност за неисполнување на обврските. Иако тие сочинуваат мал дел од целокупното податочно множество, нивното влијание врз процесот на одобрување кредити е несразмерно големо, бидејќи токму овие случаи носат најголем финансиски ризик. Отсуството на силна асиметрија и релативно чистата распределба на кредитниот рејтинг укажуваат дека оваа променлива е стабилен и доверлив индикатор, кој може ефективно да се користи во различни модели за проценка на кредитен ризик.



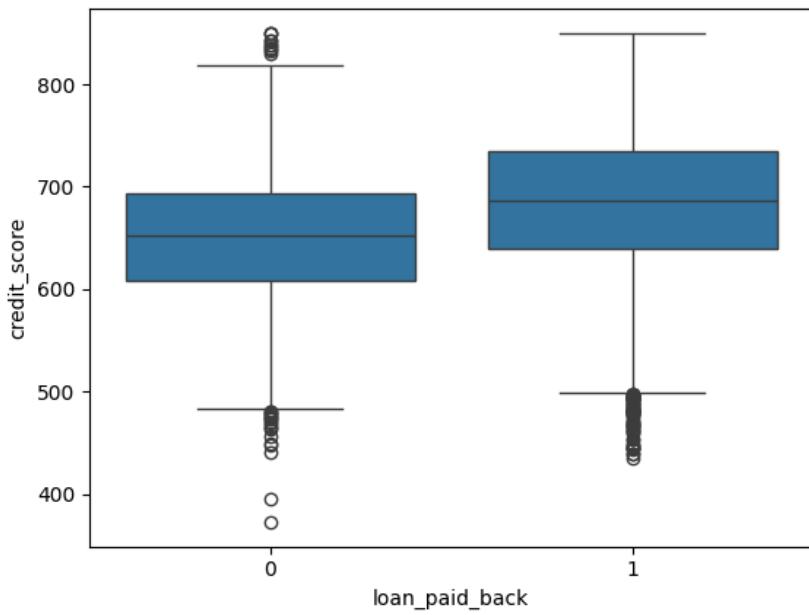
Распределбата на односот долг/приход покажува изразена десно-асиметрична форма, при што најголемиот дел од заемопримачите имаат релативно ниски вредности, најчесто помеѓу 0.05 и 0.25. Ова укажува дека поголемиот дел од корисниците имаат контролирано ниво на задолженост во однос на нивните приходи. Сепак, визуелизациите откриваат и присуство на долга „опашка“ кон повисоките вредности, со мал број на заемопримачи кај кои односот долг/приход достигнува значително повисоки нивоа.

Box-plot анализата дополнително потврдува дека овие повисоки вредности се појавуваат како екстремни случаи, односно заемопримачи со значително зголемен финансиски товар. Иако бројот на такви случаи е релативно мал, нивното значење е клучно, бидејќи тие претставуваат корисници кај кои месечните финансиски обврски сочинуваат голем дел од приходот, што директно ја зголемува веројатноста за доцнење или целосно неисполнување на кредитните обврски. Таквите случаи треба внимателно да се разгледуваат, наместо да се отстрануваат, бидејќи тие носат најголем потенцијален финансиски ризик.



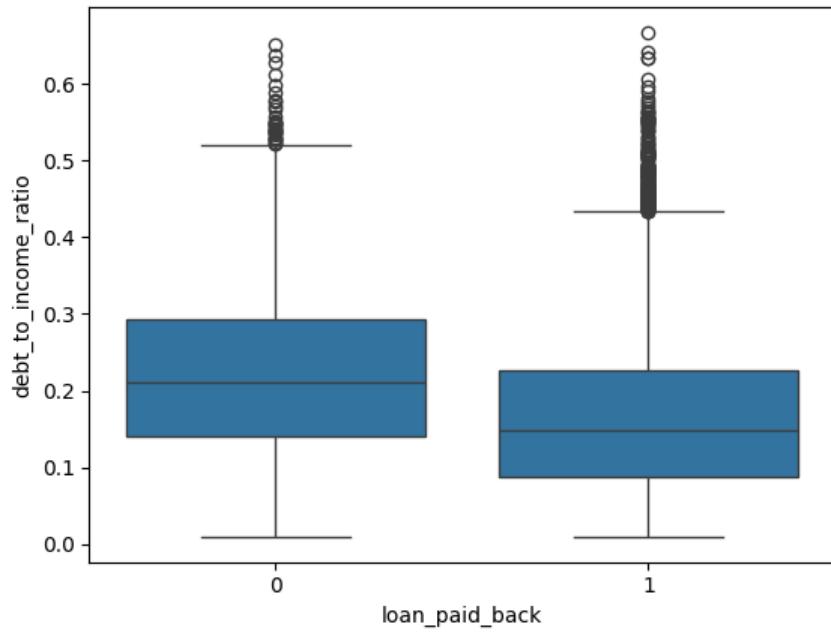
Најголемиот дел од заемопримачите се вработени, што значително доминира во однос на другите категории. Самовработените и невработените сочинуваат помал, но сè уште значаен дел од податочното множество, додека студентите и пензионерите се застапени со многу мал број на апликации. Оваа структура е очекувана за кредитно податочно множество, бидејќи стабилниот извор на приход е еден од основните предуслови за одобрување на кредит.

Доминацијата на вработените заемопримачи укажува дека податочното множество е ориентирано кон популација со релативно стабилни финансиски услови. Истовремено, присуството на категории како невработени и самовработени овозможува анализа на групи со потенцијално повисок ризик, што е важно за изградба на модели кои треба да прават разлика помеѓу стабилни и нестабилни профили на заемопримачи. Нееднаквата застапеност на категориите дополнително укажува дека работниот статус е релевантна карактеристика која може да има значајно влијание врз исходот на кредитот.



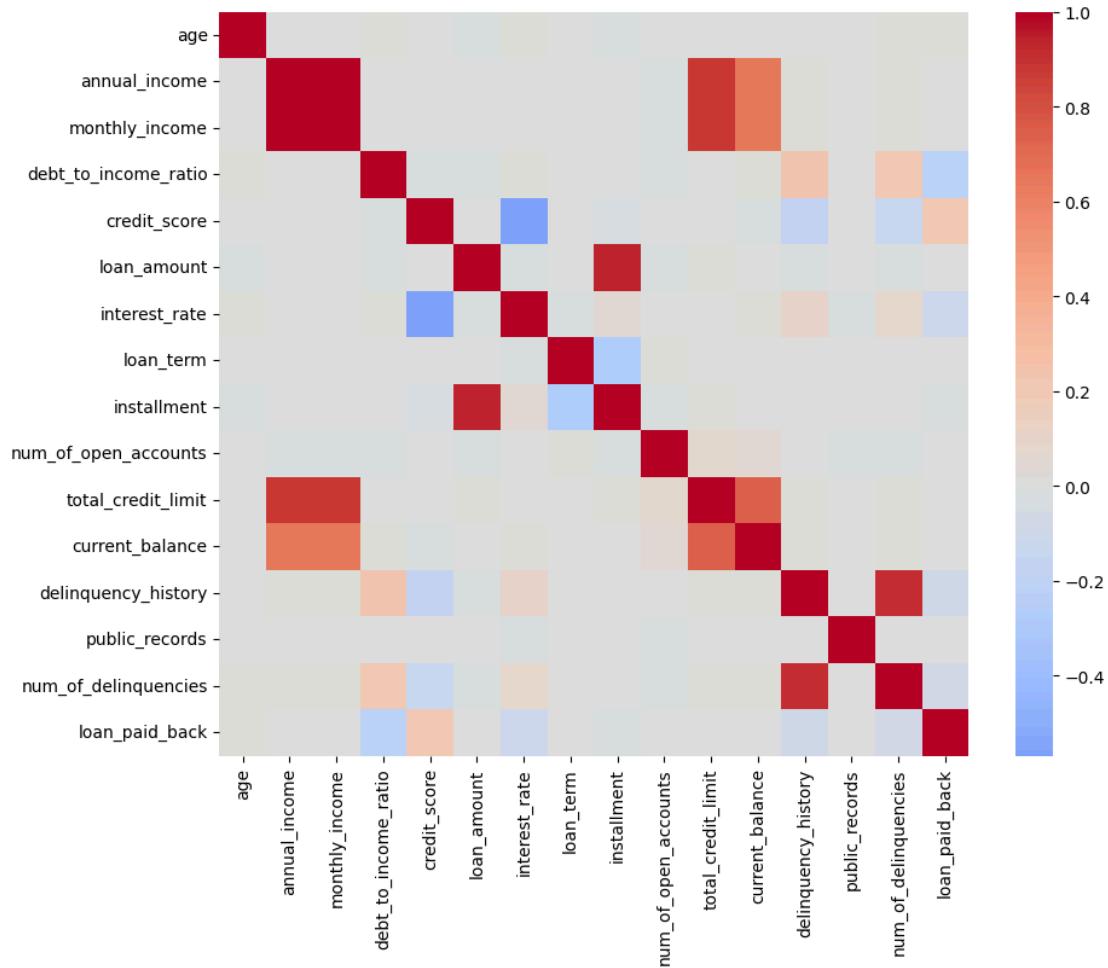
Box-plot анализата на кредитниот рејтинг во однос на статусот на отплата покажува јасна и визуелно изразена разлика помеѓу заемопримачите кои успешно го отплатиле кредитот и оние кај кој дошло до неисполнување на обврските. Заемопримачите со успешна отплата имаат повисока медијана на кредитниот рејтинг, како и повисок интерквартитен опсег, што укажува на генерално подобар кредитен профил.

Од друга страна, групата на заемопримачи кои не го отплатиле кредитот покажува пониски вредности на кредитниот рејтинг и поголема варијабилност, со присуство на екстремно ниски вредности. Овие резултати јасно ја потврдуваат улогата на кредитниот рејтинг како еден од најсилните индикатори за кредитен ризик. Разликата помеѓу двете групи е доволно изразена за да се заклучи дека оваа карактеристика има висока дискриминативна моќ и може значително да придонесе при разликување на заемопримачите со висок и низок ризик.



Анализата на односот долг/приход во однос на статусот на отплата открива спротивен тренд во споредба со кредитниот рејтинг. Заэмопримачите кои не го отплатиле кредитот имаат повисоки медијани и поширок распон на вредности на односот долг/приход, што укажува на поголем финансиски товар во однос на нивните приходи. Ова значи дека значителен дел од нивните месечни обврски е веќе ангажиран, што ја намалува нивната способност за редовна отплата на кредитот.

Кај заэмопримачите кои успешно го отплатиле кредитот, односот долг/приход е понизок и поконцентриран, што укажува на подобра финансиска рамнотежа и поголема отпорност на финансиски шокови. Присуството на екстремни вредности кај групата со неисполнување дополнително ја нагласува важноста на оваа карактеристика, бидејќи токму овие случаи претставуваат најризични профили. Овие резултати ја потврдуваат улогата на односот долг/приход како клучен фактор во проценката на кредитниот ризик и неговата практична важност во системите за одобрување на кредити.



Корелациската матрица на нумеричките карактеристики покажува неколку јасни и очекувани односи помеѓу финансиските променливи. Најизразена е речиси совершената позитивна корелација помеѓу годишен приход и месечен приход, што укажува дека овие две променливи содржат речиси идентична информација. Овој резултат е логичен, бидејќи месечниот приход претставува директна трансформација на годишниот приход, па нивната истовремена употреба не носи дополнителна информативна вредност, туку потенцијално може да воведе редундантност во моделите.

Дополнително, се забележува силна позитивна корелација помеѓу приходите и кредитен лимит, што укажува дека заемопримачите со повисоки приходи вообичаено располагаат со поголем кредитен лимит. Ова е во согласност со реалните кредитни политики, каде што кредитната способност е тесно поврзана со висината и стабилноста на приходите. Слично, постои и умерена корелација помеѓу сума на долг и месечна рата, што е очекувано бидејќи повисоките заеми резултираат со повисоки месечни рати.

Од аспект на кредитниот ризик, негативната корелација помеѓу кредитен скор и индикаторите за доцнење, како историја на доцнења(колку пати во минатото

заемопримачот доцнел со плаќања) и број на деликвенции, дополнително ја потврдува конзистентноста на податочното множество. Заемопримачите со подобар кредитен рејтинг имаат помал број на задоцнети плаќања, што ја зајакнува интерпретабилноста на овие карактеристики. Корелацијата помеѓу индивидуалните карактеристики и целната променлива `loan_paid_back` е релативно умерена, што укажува дека исходот на кредитот не зависи од една единствена карактеристика, туку од комбинација на повеќе фактори, што ја оправдува употребата на посложени модели за класификација.

Добиените резултати укажуваат на присуство на одредена редундантност помеѓу финансиските променливи, особено кај приходите, што е важно да се земе предвид при моделирањето. Истовремено, корелацијата анализа потврдува дека клучните ризик-индикатори, како кредитниот рејтинг и историјата на доцнења, имаат логични и конзистентни односи со останатите карактеристики и со исходот на кредитот. Ова создава солидна основа за понатамошно градење и споредување на различни модели за предвидување на кредитниот ризик.

3. Имплементирани модели

Секој член од тимот тренираше и оценуваше различен модел со користење на истото податочно множество со цел да се тестира кој модел би бил најсоодветен за решавање на дадениот проблем (предвидување дали ќе се одобри кредит на лице базирано на информациите кои ги имаме за него).

3.1 Невронска мрежа (MLP)

Невронската мрежа е метод за донесување одлуки кој се обидува да имитира, на поедноставен начин, како луѓето учат од искуство. Наместо да се програмира со строги правила (на пример „ако кредитниот рејтинг/скор е над 700, одобрни кредит“), невронската мрежа учи од примери. Таа ги разгледува податоците од претходни кредитни апликации и постепено учи кои комбинации од карактеристики најчесто доведуваат до одобрување или одбивање на кредит.

Во нашиот проект, целта беше да се предвиди дали едно лице ќе добие одобрен кредит врз основа на повеќе информации за него. Овие информации вклучуваат финансиски податоци, како кредитен скор и однос долг/приход, како и демографски податоци, на пример статус на вработување. Ваквиот проблем е сложен бидејќи одлуката не зависи од една единствена вредност, туку од комбинација на повеќе фактори кои меѓусебно влијаат.

Невронската мрежа што ја користевме може да се замисли како систем кој им доделува тежина на сите овие информации и на крај носи одлука. Секоја карактеристика има различна тежина/важност, а мрежата сама учи колку е значајна секоја од нив. На пример, таа може да научи дека кредитниот скор има поголемо влијание од брачниот статус, или дека висок долг може да ја намали шансата за одобрување и покрај добар приход.

Пред да започне процесот на учење, податоците беа подгответи така што невронската мрежа може да ги користи. Податоците кои се текстуални, како „вработен“ или „невработен“, беа претворени во бројки. Дополнително, сите бројчени вредности беа доведени во сличен опсег, за да не се случи една карактеристика да има преоголемо влијание само затоа што нејзините вредности се поголеми.

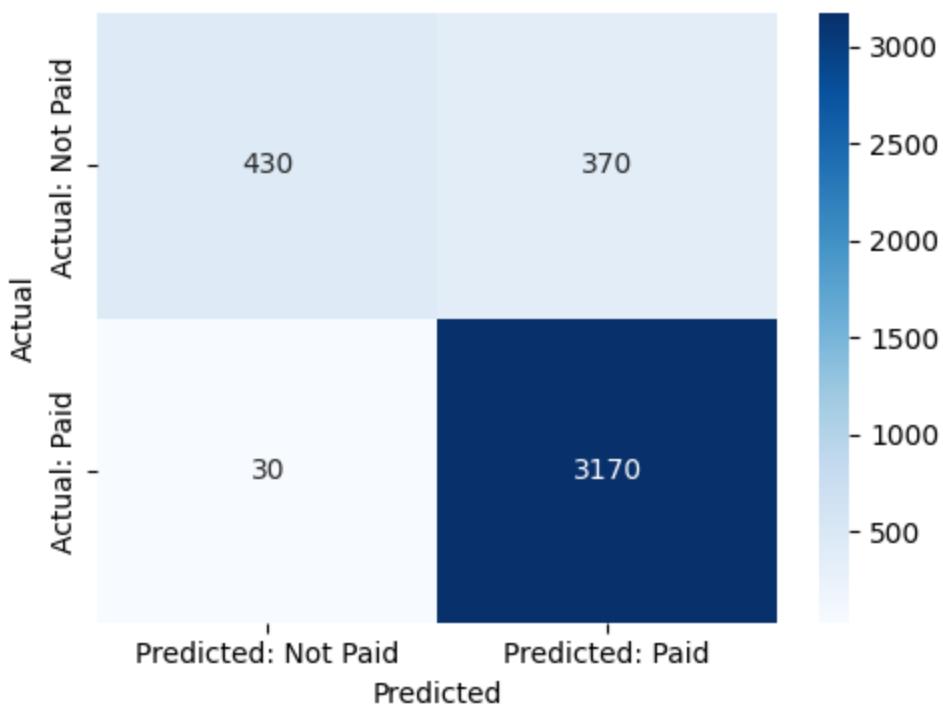
Процесот на тренирање на невронската мрежа може да се спореди со учење преку проба и грешка. На мрежата ѝ се прикажуваат голем број примери за кредитни апликации, за кои веќе се знае дали биле одобрени или не. Ако мрежата донесе погрешна одлука, таа ги коригира своите внатрешни параметри така што следниот пат ќе биде поблиску до точниот одговор. Овој процес се повторува повеќепати, сè додека моделот не почне да носи стабилни и точни одлуки.

За да се утврди колку моделот е навистина добар, тој беше тестиран на податоци кои не ги видел за време на учењето. На овој начин се проверува дали моделот навистина „разбрал“ како функционира проблемот или само ги запомнил примерите. Како мерка за успешност беше користена точноста (accuracy), односно процентот на правилно донесени одлуки. Дополнително, беше анализирано колку пати моделот точно предвидел одобрување на кредит (true positives), колку пати точно предвидел одбивање (true negatives), како и ситуациите каде што згрешил.

Извештај и конфузиона матрица од MLP моделот:

	precision	recall	f1-score	support
0	0.93	0.54	0.68	800
1	0.90	0.99	0.94	3200
accuracy			0.90	4000
macro avg	0.92	0.76	0.81	4000
weighted avg	0.90	0.90	0.89	4000

Confusion Matrix – MLP



Прикажаните резултати од MLP моделот покажуваат дека моделот има вкупна точност (accuracy) од 90%, што значи дека во најголем дел правилно предвидува дали кредитот ќе биде вратен или не. Од конфузионата матрица се гледа дека од 800 клиенти кои реално не платиле, 430 се точно идентификувани како „Not Paid“, додека 370 се погрешно класифицирани како „Paid“, што претставува критична грешка бидејќи моделот одобрува кредит на ризични клиенти. Од друга страна, кај клиентите кои реално платиле (3200), моделот е многу прецизен – 3170 се правилно класифицирани, а само 30 се погрешно одбили. Ова се одразува и во метриките: за класата „Paid“ (1) recall е многу висок (0.99), што значи дека моделот речиси секогаш ги препознава добрите клиенти, додека за класата „Not Paid“ (0) recall е значително понизок (0.54), што укажува дека моделот потешко ги детектира ризичните случаи. Иако precision вредностите се релативно високи за двете класи, понискиот F1-score за „Not Paid“ (0.68) покажува нерамнотежа во перформансите, што е важно да се земе предвид бидејќи во реален кредитен контекст лажните позитиви (одобрен кредит кој нема да биде вратен) носат поголем финансиски ризик.

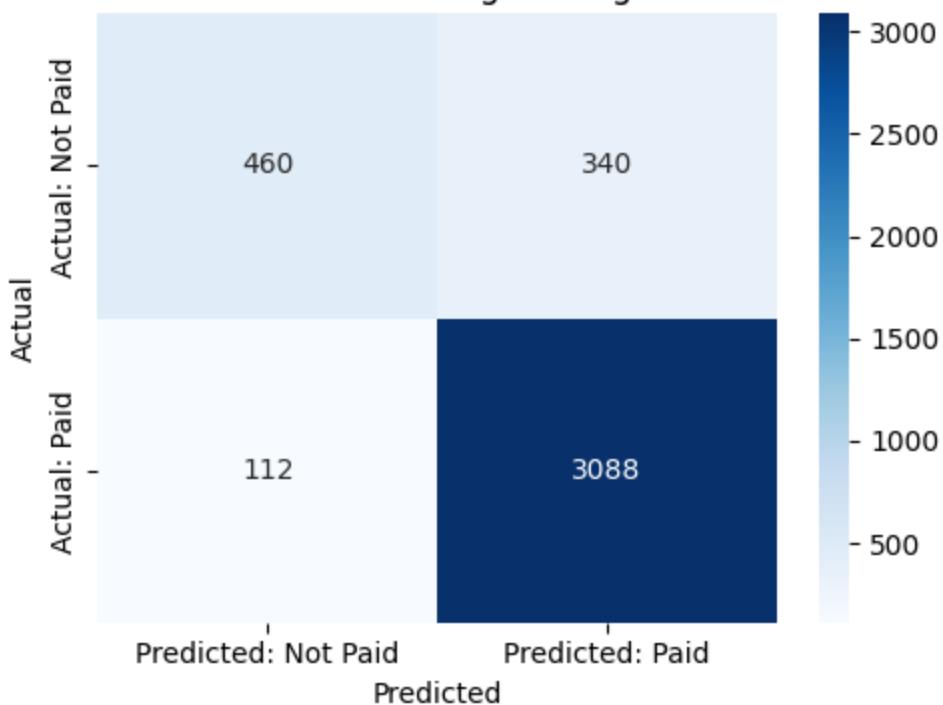
3.2 Логистичка регресија

Логистичката регресија е класичен и широко користен статистички модел за бинарна класификација, кој се применува кога целта е да се предвиди припадноста на еден примерок во една од две можни категории, како што е случајот со предвидување дали кредитот ќе биде вратен или не. Моделот функционира така што ги комбинира влезните карактеристики преку линеарна равенка со соодветни тежини (коефициенти), по што резултатот се трансформира со логистичка (sigmoid) функција за да се добие веројатност помеѓу 0 и 1. Врз основа на оваа веројатност и однапред дефиниран праг, моделот донесува конечна одлука за класата. Главна предност на Logistic Regression е неговата интерпретабилност, бидејќи секој коефициент директно ја покажува насоката и силата на влијанието на соодветната карактеристика врз исходот, што го прави особено погоден за домени како кредитно оценување каде транспарентноста и разбираливоста на одлуките се од големо значење.

Логистичката регресија е еден од најчесто користените модели за решавање проблеми на бинарна класификација, особено во доменот на финансиските анализи и проценка на кредитен ризик. Во контекст на овој проект, логистичката регресија беше искористена за предвидување дали корисникот на кредит ќе го отплати кредитот или не, врз основа на достапните демографски, финансиски и кредитни информации. Бидејќи целната променлива `loan_paid_back` има бинарни вредности (0 и 1), овој модел е соодветен за ваков тип на проблем.

	precision	recall	f1-score	support
0	0.80	0.57	0.67	800
1	0.90	0.96	0.93	3200
accuracy			0.89	4000
macro avg	0.85	0.77	0.80	4000
weighted avg	0.88	0.89	0.88	4000

Confusion Matrix - Logistic regression



Резултатите од Logistic Regression моделот покажуваат солидни и стабилни перформанси со вкупна точност (accuracy) од 89%, што укажува дека моделот релативно успешно ја извршува задачата за предвидување дали кредитот ќе биде вратен или не. Од конфузионата матрица се гледа дека од 800 клиенти кои реално не платиле, 460 се точно класифицирани како „Not Paid“, додека 340 се погрешно предвидени како „Paid“, што претставува значаен ризик во кредитен контекст бидејќи моделот одобрува кредит на дел од клиентите со висок ризик. Кај клиентите кои реално платиле, 3088 од 3200 се правилно класифицирани, а 112 се погрешно одбиени. Ова се рефлектира и во метриките, каде recall за класата „Paid“ изнесува 0.96, што значи дека моделот е многу добар во препознавање на клиенти кои ќе го вратат кредитот, додека recall за „Not Paid“ е 0.57, што укажува дека дел од ризичните клиенти остануваат недетектирани. Анализата на тежините (коефициентите) на Logistic Regression покажува дека финансиските карактеристики како credit_score, debt_to_income_ratio, interest_rate и current_balance имаат најголемо влијание врз одлуката на моделот, при што позитивните коефициенти ја зголемуваат веројатноста за класификација како „Paid“, а негативните ја зголемуваат веројатноста за „Not Paid“. Категориските карактеристики, како статусот на вработување и образовното ниво, исто така имаат значајно влијание, но во помал обем, што овозможува моделот да биде лесно интерпретабилен и транспарентен. Генерално, Logistic Regression нуди јасен увид во тоа кои фактори влијаат врз кредитната одлука, но покажува дека постои простор за подобрување во детекцијата на клиенти со висок ризик.

3.3 Random Forest

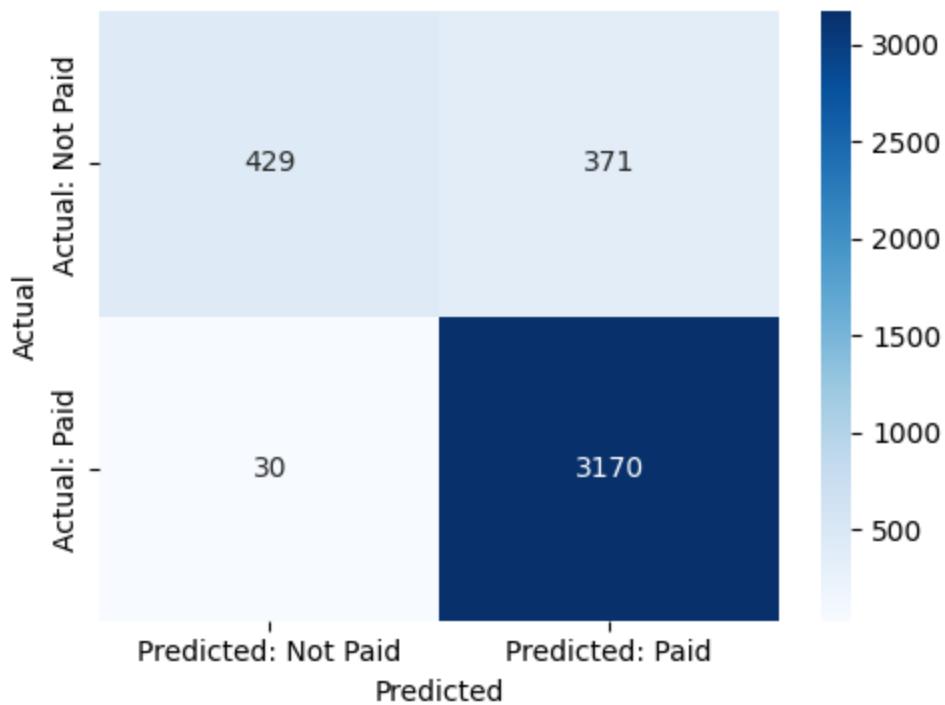
Random Forest е алгоритам за машинско учење кој се базира на комбинирање (ensemble) на повеќе дрва на одлука во еден модел. Наместо да се потпира на едно единствено дрво, кое лесно може да се пренавикне (overfitting) на податоците, Random Forest тренира голем број на дрва користејќи случајно избрани подмножества на податоци и атрибути. Кај проблемите на класификација, предвидувањето се одредува преку мнозинско гласање на сите дрва, што обично ја подобрува прецизноста и дава посигурни резултати.

Во однос на овој проект, Random Forest се користи за предвидување дали кредитот ќе биде вратен (1) или не (0). Бидејќи податочното множество содржи и нумерички и категориски атрибути, категориските атрибути најпрво се трансформираат со помош на one-hot encoding, додека нумеричките се задржуваат. Потоа, овие атрибути се комбинираат во една влезна матрица која се користи за тренирање на моделот.

Секое дрво на одлука во Random Forest учи различни правила за донесување на одлуки врз основа на случајно избраните примероци и атрибути. Поради оваа случајност, дрвата се фокусираат на различни шеми во податоците, а нивните комбинирани предикции го намалуваат влијанието на шумот.

	precision	recall	f1-score	support
0	0.93	0.54	0.68	800
1	0.90	0.99	0.94	3200
accuracy			0.90	4000
macro avg	0.91	0.76	0.81	4000
weighted avg	0.90	0.90	0.89	4000

Confusion Matrix - Random Forrest



Резултатите од Random Forest моделот покажуваат конзистентни и стабилни перформанси со вкупна точност (accuracy) од 90%, што укажува дека моделот успешно ја извршува задачата за предвидување дали кредитот ќе биде вратен или не. Од конфузионата матрица се гледа дека од 800 клиенти кои реално не платиле, 429 се точно класифицирани како „Not Paid“, додека 371 се погрешно предвидени како „Paid“, што претставува значајна грешка од аспект на кредитен ризик. Кај клиентите кои реално платиле, моделот покажува многу добри резултати, при што 3170 од 3200 се правилно класифицирани, а само 30 се погрешно одбили. Ова е потврдено и преку евалуациските метрики, каде recall за класата „Paid“ изнесува 0.99, додека за класата „Not Paid“ е 0.54, што укажува дека моделот е многу ефикасен во препознавање на клиенти со низок ризик, но има ограничена способност за детекција на ризични клиенти. Precision вредностите се високи за двете класи (0.93 за „Not Paid“ и 0.90 за „Paid“), што значи дека кога моделот ќе донесе одлука, таа е во најголем дел точна. Генерално, Random Forest моделот нуди добра рамнотежа помеѓу стабилност и перформанси, но слично како и кај останатите модели, дополнително прилагодување на прагот на одлучување или казнување на лажните позитиви би можело да ја подобри неговата применливост во реален кредитен контекст.

3.4 Gradient Boosting / XGBoost

XGBoost (eXtreme Gradient Boosting) е напреден алгоритам за машинско учење кој работи така што комбинира повеќе едноставни модели (одлучувачки дрва) во еден силен и прецизен модел. Секое ново дрво се обидува да ги поправи грешките направени од претходните, што резултира со подобри и постабилни предвидувања. XGBoost е познат по високата точност, способноста да работи со големи податочни сетови и добрата контрола на преобучување (overfitting).

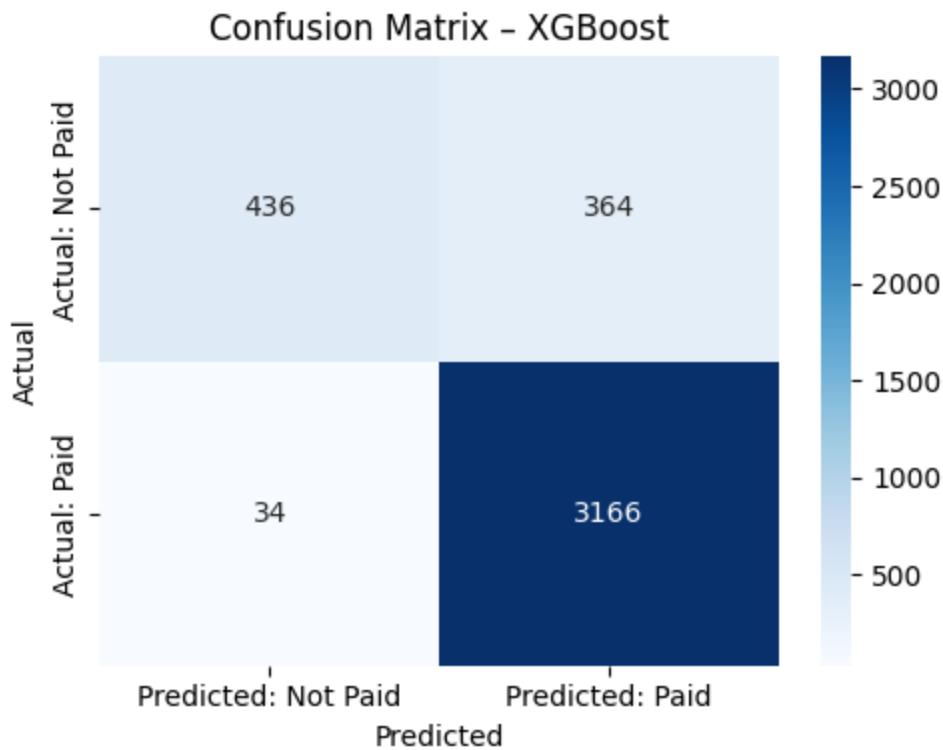
Овој модел е особено соодветен за проблемот на кредитен ризик, бидејќи може да фати сложени односи помеѓу финансиските индикатори, кредитната историја и однесувањето на корисниците, нешто што поедноставни модели често не успеваат да го направат.

Пред тренирањето, податоците беа темелно подгответи. Категориските карактеристики како пол, брачен статус, вработеност, намена на кредитот итн беа трансформирани во нумерички вредности преку *one-hot encoding*, со што моделот може да ги интерпретира овие информации.. Целната променлива (*loan_paid_back*) беше бинарна, каде што вредност 1 означува успешно вратен кредит, а 0 невраќање.

Податоците беа поделени на тренинг (80%) и тест сет (20%), со што се овозможи објективна евалуација на перформансите на моделот.

XGBoost моделот беше трениран со 500 дрва, умерена длабочина и намалена стапка на учење, со цел да се постигне добар баланс помеѓу прецизност и генерализација. Користена беше *log-loss* функција за време на тренингот, која го казнува моделот кога е премногу самоуверен во погрешни предвидувања.

	precision	recall	f1-score	support
0	0.93	0.55	0.69	800
1	0.90	0.99	0.94	3200
accuracy			0.90	4000
macro avg	0.91	0.77	0.81	4000
weighted avg	0.90	0.90	0.89	4000



Резултатите од XGBoost моделот покажуваат стабилни и балансирани перформанси со вкупна точност од 90%, што укажува дека моделот успешно ја разликува категоријата на клиенти кои ќе го вратат кредитот од оние кои нема да го вратат. Од конфузионата матрица се гледа дека од 800 реално неплатени кредити, 436 се точно класифицирани како „Not Paid“, додека 364 се погрешно предвидени како „Paid“, што претставува најкритичниот тип на грешка во кредитен контекст. Кај клиентите кои реално платиле, моделот покажува одлични резултати – 3166 од 3200 се правилно класифицирани, со многу мал број лажни негативи (34). Ова е потврдено и преку метриките, каде recall за класата „Paid“ изнесува 0.99, додека за „Not Paid“ е 0.55, што укажува дека моделот е посензитивен кон детекција на добри клиенти отколку на ризични. Анализата на важноста на карактеристиките покажува дека моделот најмногу се потпира на статусот на вработување (особено категориите Unemployed и Student), кредитниот grade/subgrade, како и клучни финансиски индикатори како debt-to-income ratio и credit score, што е во согласност со доменската логика на проценка на кредитен ризик. Овие резултати укажуваат дека XGBoost моделот е ефикасен и интерпретабилен, но дека дополнително прилагодување на прагот или тежините на грешките би можело да ја подобри детекцијата на ризични клиенти.

3.5 LightGBM

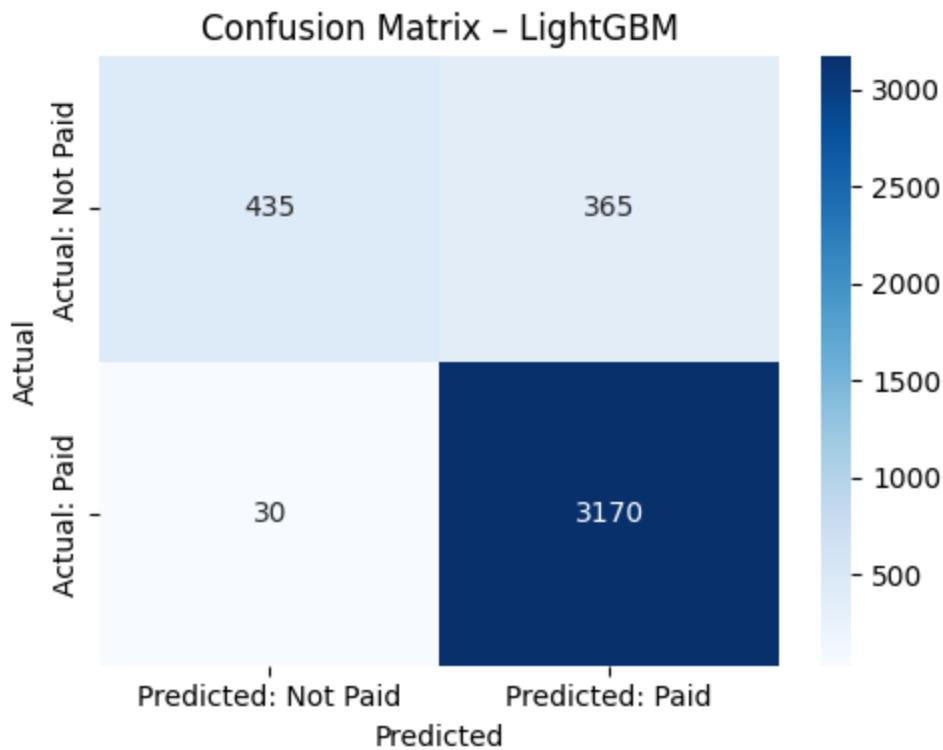
LightGBM (Light Gradient Boosting Machine) е gradient boosting framework дизајниран за **висока брзина, ефикасност и скалабилност**, особено при работа со големи и комплексни табеларни податоци. Во споредба со традиционалните gradient boosting имплементации, LightGBM е оптимизиран да троши помалку меморија и да тренира побрзо, без значајна загуба на точност. Една од главните карактеристики на LightGBM е користењето на **histogram-based splitting**. Наместо да работи со континуирани вредности, податоците се групираат во бинови (histograms), што овозможува побрзо пресметување на split точките и подобра ефикасност при големи податочни множества. Дополнително, LightGBM применува **leaf-wise растење на decision trees**, при што секогаш се проширува листот со најголема грешка (loss). Овој пристап овозможува побрза конвергенција и често подобри перформанси од класичниот level-wise раст, но

За да се постигне оптимален баланс помеѓу **перформанси и стабилност на моделот**, се подесуваат клучни хиперпараметри, како што се:

- **Number of estimators (n_estimators)** – бројот на дрва во моделот
- **Learning rate** – брзината со која моделот учи од секое ново дрво
- **Tree complexity** (пр. num_leaves, max_depth) – контрола на сложеноста и спречување на overfitting

Со соодветна комбинација на овие параметри, LightGBM овозможува изградба на брзи, точни и робусни модели.

	precision	recall	f1-score	support
0	0.94	0.54	0.69	800
1	0.90	0.99	0.94	3200
accuracy			0.90	4000
macro avg	0.92	0.77	0.81	4000
weighted avg	0.90	0.90	0.89	4000



Резултатите од LightGBM моделот покажуваат многу добри и стабилни перформанси со вкупна точност (accuracy) од 90%, што значи дека моделот во најголем дел правилно предвидува дали кредитот ќе биде вратен или не. Од конфузионата матрица се гледа дека од 800 реално неплатени кредити, 435 се точно класифицирани како „Неплатени“, додека 365 се погрешно предвидени како Платени“, што претставува најrizичната грешка во кредитен контекст бидејќи може да доведе до одобрување на кредит на клиент кој нема да го врати. Кај клиентите кои реално платиле, моделот е исклучително прецизен – 3170 од 3200 се правилно класифицирани, а само 30 се погрешно одбиеани. Ова се потврдува и преку classification report, каде recall за класата „Paid“ (1) изнесува 0.99, што значи дека моделот речиси секогаш ги препознава клиентите кои ќе платат, додека recall за „Неплатени“ (0) е 0.54, што укажува дека моделот потешко ги детектира ризичните клиенти. Precision за „Неплатени“ е 0.94, што значи дека кога моделот ќе предвиди „Неплатени“, тоа најчесто е точно, но понискиот F1-score за оваа класа (0.69) покажува дека има простор за подобрување во балансот меѓу прецизност и пронаоѓање на сите ризични случаи. Генерално, LightGBM нуди силни резултати и брза имплементација, но како и кај останатите модели, дополнително прилагодување на прагот на одлучување или поголемо казнување на ложните позитиви би можело да ја зголеми практичната вредност на моделот во реална кредитна проценка.

Резултатите од LightGBM моделот ја потврдуваат доминантната улога на финансиските карактеристики во процесот на проценка на кредитниот ризик. Анализата на важноста на карактеристиките покажува дека моделот најмногу се потпира на нумерички индикатори,

при што credit_score и debt_to_income_ratio се убедливо највлијателни фактори, следени од interest_rate, current_balance, total_credit_limit, annual_income и installment. Ова укажува дека LightGBM примарно ја базира одлуката на објективни финансиски показатели кои директно ја одразуваат платежната способност на клиентот. Категориските карактеристики, како статусот на вработување (особено Unemployed, Student и Retired), полот, образовното ниво и целта на кредитот, имаат умерено, но сепак значајно влијание, додека деталните grade_subgrade категории се користат како дополнителен сигнал со релативно помала тежина поединечно. Во комбинација со евалуациските резултати, каде моделот постигнува точност од 90% и многу висок recall за класата „Paid“ (0.99), може да се заклучи дека LightGBM е силен и стабилен модел кој ефективно ги идентификува клиентите со низок ризик, но има ограничена способност за детекција на сите ризични случаи. Овие наоди укажуваат дека дополнително прилагодување на одлучувачкиот праг или воведување на асиметрично казнување на грешките би можело да ја подобри практичната применливост на моделот во реален кредитен систем.

4. Евалуација и споредба на моделите

4.1 Методологија за евалуација

За да се обезбеди објективна и сигурна споредба помеѓу моделите, беа применети повеќе стратегии за евалуација.

Train-test split

Податоците беа поделени на тренинг и тест сет. Моделите се тренираа исклучиво врз тренинг сетот, додека тест сетот се користеше само за финална евалуација. Овој пристап овозможува проценка на перформансите врз податоци што моделот претходно не ги има видено.

K-fold cross-validation

K-fold cross-validation беше користен со цел да се намали зависноста од една конкретна поделба на податоците. Тренинг сетот се дели на K подгрупи, при што моделот се тренира и валидира K пати, секој пат користејќи различен дел како валидациски сет. Крајниот резултат претставува просек од сите валидации.

Споредба на тренинг и тест перформанси

Беа споредени резултатите добиени на тренинг и тест податоците (Accuracy и ROC AUC) со цел да се идентификува појава на overfitting или underfitting. Голема разлика меѓу тренинг и тест резултатите укажува на преголемо прилагодување кон тренинг податоците.

Техничка споредба

- **Logistic Regression** е линеарен модел со висока интерпретабилност и брзо тренирање, но со ограничена способност за моделирање на сложени односи.
- **Random Forest** користи ансамбл од дрва на одлука и е робустен кон шум и варијации во податоците.
- **Gradient Boosting / XGBoost** и **LightGBM** се boosting методи кои градија последователни дрва за минимизирање на грешките од претходните модели.
- **LightGBM** дополнително е оптимизиран за брзина и ефикасност преку histogram-based splitting и leaf-wise растење на дрвата.
- **Neural Network (MLP)** користи повеќеслојна нелинеарна архитектура, но бара внимателна нормализација и подесување на параметрите.

4.2 Клучни забелешки

Посложените модели, како **LightGBM**, **XGBoost** и **MLP**, постигнаа повисока точност на тренинг податоците, благодарение на нивната способност да фаќаат сложени и нелинеарни зависности. Сепак, ова често доаѓа со зголемен ризик од overfitting.

Поедноставните модели, особено **Logistic Regression**, често покажаа подобра способност за генерализација, со помала разлика помеѓу тренинг и тест перформансите. Иако апсолутната точност е пониска, стабилноста ги прави добар референтен модел.

Стабилност на ансамбл методите

Ансамбл методите, како **Random Forest** и **LightGBM**, покажаа стабилни резултати низ различни cross-validation фолдови, што укажува на нивна робустност и доверливост за практична употреба.

Техничка споредба

- **LightGBM** и **XGBoost** понудија најдобар баланс помеѓу точност, стабилност и ефикасност.
- **Random Forest** дава добри резултати со минимално подесување, но генерално е послаб од boosting моделите.
- **MLP** постигнува високи тренинг резултати, но е почувствителен на параметри и количина на податоци.
- **Logistic Regression** останува најдноставен, најбрз и најлесен модел за интерпретација.

5. Комбинирана анализа на моделите и влијание на карактеристиките

5.1 Споредба на сите модели и потребата од централизирана анализа

Во рамки на проектот беа имплементирани повеќе различни модели за предвидување на кредитно одобрување. Секој од овие модели пристапува кон проблемот на различен начин и има свои предности и недостатоци. Некои модели се поедноставни и полесни за толкување, додека други се посложени и можат да фатат покомплексни односи во податоците. Меѓутоа, доколку секој модел се анализира изолирано, постои ризик заклучоците да бидат пристрасни или нецелосни. Поради тоа, беше креиран еден централен фајл за евалуација, кој претставува заедничка основа за анализа и споредба на сите модели.

Овој фајл беше дизајниран така што:

- сите модели се тестираат на **исти податоци**,
- се користат **исти критериуми за мерење на успешноста**,
- резултатите се прикажуваат на унифициран начин,
- и се овозможува директна споредба помеѓу моделите.

На овој начин, секоја разлика во резултатите навистина потекнува од квалитетот на моделот, а не од различни услови на тестирање. Ова беше клучно за да можеме објективно да процениме кој пристап е најсоодветен за реална примена.

5.2 Релевантност на точноста на моделите

Во почетната фаза од анализата, повеќето модели покажаа релативно висока точност. Ова лесно може да доведе до заклучок дека моделот со највисока точност е автоматски најдобар избор. Сепак, во контекст на кредитирање, ваквиот пристап е поедноставен и потенцијално опасен. Причината за тоа е што не сите грешки имаат иста цена. Во кредитен систем, одлуката не е апстрактна – таа има директни финансиски последици. Затоа, наместо да гледаме само колку често моделот е „во право“, почнавме да анализираме каков тип на грешки прави.

Разгледавме две основни ситуации:

- кога моделот **одобрува** кредит на клиент што реално **не треба** да го добие,
- и кога моделот **одбива** кредит на клиент што реално би го вратил.

Во пракса, овие две ситуации немаат иста тежина. Давањето кредит на клиент што нема капацитет да го врати носи директен финансиски ризик, можни загуби и дополнителни трошоци. Од друга страна, одбивањето на добар клиент претставува изгубена можност, но не и директна загуба од неповратен кредит. Поради тоа, донесовме јасна одлука дека:

грешката каде што моделот одобрува ризичен кредит (*false positive*) е значително посериозна од грешката каде што одбива добар клиент (*false negative*).

5.3 Ризик-ориентирана евалуација: *false positives* како приоритет

За да го преточиме ова размислување во конкретен критериум за избор, при евалуацијата воведовме **различна „тежина“ на грешките**. Конкретно, одлучивме дека: *false positive* грешката ја третираме како 5 пати полоша од *false negative* грешката. Ова не е произволна одлука, туку логично произлегува од реалниот ризик во кредитирање. Со таков пристап, модел кој прави малку повеќе „безбедни“ грешки, но значително помалку ризични одобрувања, се смета за подобар избор од модел со поголема вкупна точност, но со повеќе опасни грешки.

При анализата, ги споредувавме моделите не само по вкупната точност, туку и:

- колку често одобруваат ризични клиенти,
- колку се „конзервативни“ во одлуките,
- и колку се стабилни на различни тестирања.

Овој начин на размислување го помести фокусот од „најдобра бројка“ кон **најразумна одлука**.

5.4 Ансамбл пристап: комбинирање на повеќе модели

Покрај поединечната споредба на моделите, дополнително имплементирајме и ансамбл пристап, односно комбинирање на предвидувањата од повеќе модели. Ансамблот може најдобро да се објасни преку секојдневна аналогија: наместо да се донесе важна одлука врз основа на мислењето на еден експерт, се консултираат повеќе експерти, а финалната одлука се носи земајќи ги предвид сите мислења.

Во нашиот случај:

- различни модели „гледаат“ различни аспекти од податоците,
- секој модел има свои силни и слаби страни,
- комбинирањето помага да се намали влијанието на индивидуалните слабости.

Ансамблот ни служеше како:

- проверка на стабилноста на поединечните модели,
- дополнителена информација дали некој модел е премногу оптимистичен или премногу конзервативен,
- начин да се види дали комбинираната одлука го намалува бројот на ризични грешки.

Иако ансамблот покажа добра стабилност, при финалната одлука сепак поголем приоритет му дадовме на модел кој самостојно покажува најдобар баланс според нашите ризик-критериуми.

5.5 Финален избор - XGBoost

По систематска анализа и споредба на повеќе модели, финалниот избор падна на XGBoost. Одлуката не беше донесена врз основа на една метрика или највисока точност, туку врз основа на целокупното однесување на моделот во контекст на реалниот проблем.

Во текот на анализата:

- Податоците беа поделени на train, validation и test сет со стратификација.
- Прагот (threshold) не беше фиксен на 0.5, туку беше оптимизиран според дефинирана cost-функција каде лажно позитивните случаи се 5 пати посакани од лажно негативните.
- Оптималниот праг беше избран врз validation сет, а финалната евалуација беше направена врз независен test сет.

На validation сетот беше добиен праг од 0.66, со вкупен cost од 1560.

На test сетот, со истиот праг, cost беше 1628.

Разликата помеѓу validation и test резултатите е мала, што укажува на добра стабилност и способност за генерализација. Немаше значителен пад на перформансите, ниту драматично зголемување на лажно позитивните случаи.

Во test сетот:

- Лажно позитивни случаи (ризични клиенти што би биле одобрени) = 142
- Лажно негативни случаи (добрите клиенти што би биле одбиени) = 918

Со оглед на тоа што FP се 5 пати посакани, моделот беше намерно поставен да биде поконзервативен и да минимизира ризични одобрувања, дури и по цена на одбивање на дел од добрите клиенти.

Ова однесување е во согласност со поставената деловна логика: подобро е да се пропушти дел од потенцијалниот профит отколку да се одобрят значителен број ризични кредити.

XGBoost не беше избран само затоа што имаше добри бројки, туку затоа што:

- покажа стабилни резултати на независен test сет,
- успешно го минимизираше бројот на ризични одобрувања според дефинираната cost логика,
- и покажа способност да учи сложени интеракции помеѓу факторите (што беше потврдено преку анализата на исклучоци во EDA фазата).

5.1 Влијание на карактеристиките и доверба во одлуките

По финалното тренирање беше извршена анализа на важност на карактеристиките (feature importance) со цел да се разбере кои фактори најмногу влијаат врз одлуките.

Анализата покажа дека:

- Статусот на вработување има најсилен придонес според gain метриката, особено категоријата „Unemployed“.
- debt_to_income_ratio е една од најсилните нумерички варијабли и беше и најчесто користена во моделот.
- credit_score има значајна улога и потврдува јасна врска помеѓу повисок скор и понизок ризик.
- Дополнителни финансиски фактори како current_balance, annual_income, interest_rate и loan_amount се користат често, што укажува дека моделот комбинира повеќе аспекти од финансискиот профил.

Овие резултати се конзистентни со претходната експлоративна анализа, каде беше утврдено дека:

- Повисок DTI систематски го зголемува ризикот.
- Понизок credit score е поврзан со повисока веројатност за неплаќање.
- Постојат исклучоци (на пр., висок скор но сепак неплаќање), што ја оправдува употребата на модел кој може да учи нелинеарни интеракции.

Фактот што најважните карактеристики се економски логични и интуитивно оправдани ја зголемува довербата во моделот. Тој не учи случајни корелации, туку обрасци кои се во согласност со финансиската логика: комбинација од способност за плаќање (DTI, income), кредитна историја (credit_score, delinquency) и социо-економски статус (employment_status).

Ова покажува дека проектот не се фокусираше само на имплементација на алгоритам, туку на изградба на одговорен систем за поддршка на одлуки, каде што:

- грешките се третираат асиметрично,
- перформансите се проверуваат на независен тест сет,
- и одлуките се објасниви и конзистентни со реалниот контекст.

Токму ваквиот структуриран и одговорен пристап ја прави примената на машинското учење релевантна и применлива во практични финансиски системи.

6. Анализа на исклучоци (Outliers) и Human-in-the-Loop пристап

Во текот на анализата беа идентификувани специфични исклучоци — клиенти со висок credit_score кои сепак не го вратиле кредитот, како и клиенти со низок debt_to_income_ratio кои не го исплатиле долгот. Овие случаи јасно покажуваат дека ризикот не може да се објасни преку една варијабла или едноставно правило.

Токму овде се гледа зошто XGBoost е соодветен избор. За разлика од линеарните модели, кои претпоставуваат дека ефектот на секоја карактеристика е линеарен и независен, XGBoost гради ансамбл од одлучувачки дрва кои можат да:

- фатат нелинеарни врски,
- препознаат интеракции помеѓу варијабли,
- научат повеќе различни „патишта“ што водат до ист исход.

На пример, моделот може да научи правило од типот:

- висок credit_score сам по себе значи низок ризик,
- но ако е комбиниран со висок debt_to_income_ratio, ризикот значително се зголемува.

Или:

- низок DTI не значи безризичен клиент ако постои историја на доцнења и повисока каматна стапка.

Овие сложени интеракции беа индицирани и во EDA фазата преку анализа на исклучоците. Затоа, изборот на XGBoost не е само техничка одлука, туку логична последица од природата на податоците.

6.1 Probability of Default (PD) и практична примена

Моделот не мора да дава само бинарна одлука (одобрени/одбиј). XGBoost природно враќа веројатност — во овој случај, веројатност дека клиентот ќе го врати кредитот. Со едноставна трансформација, може да се прикаже и Probability of Default (PD), односно:

$$PD = 1 - P(\text{loan_paid_back} = 1) = 1 - \text{Веројатност клиентот да го врати кредитот}$$

Ова има практична вредност:

- Наместо „да“ или „не“, системот може да прикаже ризичен скор (на пример PD = 0.18).
- Прагот може да се прилагоди динамички според ризичната политика.
- Клиентите може да се категоризираат во ризични сегменти (низок, среден, висок ризик).

Овој пристап овозможува флексибилност — одлуката не е статична, туку зависи од апетитот за ризик на институцијата.

6.2 Објаснување на конкретна одлука

Покрај глобалната важност на карактеристиките, XGBoost овозможува и локална објасливост. За конкретен клиент може да се анализира:

- кои фактори ја зголемиле веројатноста за одбивање,
- кои фактори ја намалиле.

Ова е клучно од аспект на транспарентност и доверба.

Од перспектива на сопственик на банка, главните грижи се:

- Како знаеме дека моделот не прави произволни одлуки?
- Можеме ли да објасниме зошто е одбиен конкретен клиент?
- Дали системот може да се прилагоди ако ризичната стратегија се промени?
- Како да се намали регулаторниот и репутациски ризик?

Комбинацијата од:

- анализа на исклучоци,
- глобална feature importance,
- можност за пресметка на PD,
- и потенцијална локална објасливост,

овозможува моделот да биде дел од Human-in-the-Loop систем. Во ваков систем, автоматската проценка служи како прв филтер, додека граничните или необичните случаи се ескалираат за човечка ревизија.

Со тоа се постигнува баланс помеѓу:

- ефикасност (автоматизација),
- контрола (човечка проверка),

- и управување со ризик.

Овој пристап покажува дека моделот не е „црна кутија“, туку контролиран инструмент за поддршка на одлуки, кој може да се адаптира, објасни и усогласи со реалните деловни цели.

7. Споредба со слични модели

Во научната литература за предвидување на кредитен ризик се забележуваат многу слични заклучоци со оние добиени во нашиот модел, особено во поглед на улогата на кредитниот рејтинг/скор, односот долг/приход и статусот на вработување. Така, на пример, во трудот „Loan Default Prediction and Feature Importance Analysis Based on XGBoost“ објавен во списанието *European Journal of Business and Economic Management* авторите применуваат XGBoost модел врз податочно множество со атрибути како кредитен скор, приход, debt-ratio и историја на доцнења. Нивната анализа на важноста на карактеристиките покажува дека променливи поврзани со оптовареност со долг (како debt-ratio и кредитна употреба) и кредитната историја спаѓаат меѓу најкритичните фактори за предвидување на default, при што високото ниво на долг во однос на приходот значајно ја зголемува веројатноста за неплаќање. Ова е во целосна согласност со нашиот резултат дека односот долг/приход има најсилно негативно влијание врз одлуките на моделот, бидејќи во двета случаи токму мерките на задолженост во однос на приходот се препознаваат како клучен ризичен индикатор.

Слична констатација се јавува и во трудот „Explainable prediction of loan default based on machine learning“, објавен во списанието *Finance Research Letters*, каде се користат модели како Random Forest, XGBoost и LightGBM врз податоци слични на LendingClub. Со примена на SHAP-анализа авторите покажуваат дека loan grade, кредитниот рејтинг, loan term и loan amount се меѓу највлијателните фактори за предвидување на default, при што повисокиот кредитен степен и подобриот кредитен рејтинг значително ја намалуваат веројатноста за неплаќање. Ова директно кореспондира со наодот во нашиот модел дека кредитниот рејтинг/скор има најсилно позитивно влијание: во двета случаи кредитниот рејтинг функционира како синтетичка мерка на скупната кредитна доверливост на корисникот, која моделот ја користи како примарен сигнал за разликување на клиенти со низок и висок ризик.

Дополнителна поддршка за улогата на статусот на вработување и стабилноста на доходот се наоѓа во трудот „Explainable Machine Learning for Loan Default Prediction“, објавен во *International Journal of Artificial Intelligence in Business, Data Analytics, and Cloud Computing*, каде авторите тренираат Random Forest и Gradient Boosting модели на кредитни податоци

и ги објаснуваат резултатите со LIME и SHAP. Нивните наоди укажуваат дека Debt-To-Income (DTI) ratio, каматната стапка и износот на заемот се меѓу најважните предиктори на ризик, а покрај тоа нагласуваат дека карактеристики поврзани со статус на вработување и стабилност на приходот значајно влијаат врз веројатноста за default, при што стабилно вработените клиенти покажуваат понизок ризик во споредба со невработените или со несигурни извори на приход. Ова е усогласено со нашите резултати, каде статусот на вработување игра значајна улога и моделот учи различни ефекти за различните категории („вработен“, „самовработен“, „невработен“), што на практично ниво значи дека и кај однапред дефиниран кредитен скор и однос долг/приход, стабилната вработеност може да го намали, а нестабилната да го зголеми проценетиот ризик.

Сумирало, трите наведени студии – независно ги идентификуваат истите групи на фактори како доминантни: кредитен рејтинг/степен, степен на задолженост како DTI или debt-ratio и индикатори за вработување и приход. Ова силно потврдува дека нашите заклучоци – дека кредитниот скор има најсилно позитивно влијание, односот долг/приход најсилно негативно влијание, а статусот на вработување значајна и диференцирана улога – не се изолирани, туку се конзистентни со резултатите добиени во современата литература за предвидување на кредитен ризик.

7. Заклучок

Во овој проект беше извршена детална анализа на податоци за заемопримачи со цел да се изгради систем кој може реално, стабилно и одговорно да предвиди дали заем ќе биде вратен или не. Податоците беа внимателно анализирани преку експлоративна анализа, тестирање на хипотези и испитување на исклучоци (outliers), со цел подобро да се разберат обрасците што стојат зад ризикот од неплаќање. Сите модели беа тренирани и евалуирани под исти услови (со train, validation и test поделба), што овозможи фер и директна споредба. При евалуацијата не се земаше предвид само точноста, туку и реалниот деловен ризик. Лажно позитивните предвидувања (одобрување заем на клиент кој нема да го врати) беа третирани како пет пати посериозна грешка од лажно негативните случаи. Прагот на одлука не беше фиксен, туку беше оптимизиран според оваа cost-функција на validation сет и потоа тестиран на независен test сет.

XGBoost се издвојуваше не само по перформанси, туку и по стабилност. Разликата помеѓу validation и test резултатите беше мала, што укажува на добра способност за генерализација. Моделот успешно го минимизираше бројот на ризични одобрувања според поставената деловна логика, без драматичен пад на стабилноста.

Дополнително, анализата на исклучоци покажа дека ризикот не произлегува од една варијабла, туку од комбинација на повеќе фактори — на пример висок кредитен скор комбиниран со висок debt-to-income однос. Ова ја оправдува употребата на XGBoost, кој може да фати нелинеарни односи и интеракции помеѓу карактеристиките, наместо да се потпира на едноставни линеарни претпоставки.

Преку анализа на важноста на карактеристиките беше утврдено дека моделот се потпира на економски логични фактори како debt-to-income ratio, credit score и employment status. Ова ја зголемува довербата дека моделот учи смислени обрасци, а не случајни корелации. Дополнително, бидејќи моделот враќа веројатност, тој може да се користи за пресметка на Probability of Default (PD), што овозможува флексибилно поставување на прагови според ризичната стратегија.

Комбинацијата од:

- cost-базирана евалуација,
- стабилна генерализација,
- анализа на исклучоци,
- објасливост на карактеристиките,
- и можност за пресметка на PD

ововозможува моделот да се имплементира како дел од Human-in-the-Loop систем, каде автоматската проценка служи како прв филтер, а граничните случаи можат да бидат дополнително разгледани од човек.

Секупно, проектот покажа дека преку структурирана анализа, споредба на повеќе модели, внимателна евалуација според реален трошок и тимска соработка, може да се изгради модел кој има вистинска практична вредност и може одговорно да се примени во систем за поддршка при донесување финансиски одлуки.

8. Референци

1. „Loan Default Prediction and Feature Importance Analysis Based on XGBoost“ во *EJBEM*,
2. [Explainable prediction of loan default based on machine learning models - ScienceDirect](#)
3. „Explainable Machine Learning for Loan Default Prediction“ во *International Journal of Artificial Intelligence in Business, Data Analytics, and Cloud Computing*